

FIAP — Faculdade de Informática e Administração Paulista

DevOps e Arquitetura Cloud

ToggleMaster: de Monólito a um Ecossistema de Microsserviços Orquestrado em Kubernetes (AWS EKS)

Relatório de Entrega — Tech Challenge Fase 2

Karlos Rodrigues — RM 374567 — Discord: karlos.rodrigues

Sumário

1. Introdução e Contexto do Projeto	3
2. Arquitetura da Solução	3
3. Containerização com Docker	5
4. Infraestrutura Provisionada na AWS	8
5. Orquestração com Kubernetes	10
6. Ingress e Acesso Externo	11
7. Escalabilidade Automática (HPA)	12
8. Desafios e Decisões Técnicas	13
9. Considerações Finais e Links do Projeto	16
Apêndice A — Evidências de Execução	17
Apêndice B — De-para: Requisitos do Enunciado × Entregas	17

1. Introdução e Contexto do Projeto

Na Fase 1, entreguei o ToggleMaster como um MVP monolítico: uma aplicação Flask com PostgreSQL, publicada numa EC2 com banco RDS privado. Já naquele relatório eu tinha apontado candidatos naturais a serem extraídos como serviços independentes — um de avaliação de flags, de leitura pesada e que se beneficiaria de cache próprio; um de administração das flags; e um de autenticação. É essa separação que eu executo agora, nesta Fase 2.

O motivo é o gargalo que eu já esperava desde a Fase 1: escalabilidade grosseira, ou seja, não dá pra escalar só o caminho de leitura sem escalar a aplicação inteira junto. Com a plataforma validada e a base de clientes crescendo, a diretoria fictícia da DevOps Solutions Inc. — o cenário que o enunciado propõe — decidiu que era hora de reescrever o sistema como um conjunto de microsserviços distribuídos, orquestrados em Kubernetes. Coube a mim tocar essa reescrita.

Meu trabalho nesta fase foi containerizar os cinco microsserviços que recebi prontos da equipe de arquitetura (`auth-service`, `flag-service`, `targeting-service`, `evaluation-service` e `analytics-service`), provisionar a infraestrutura de nuvem que eles precisam, e implantar tudo num cluster Kubernetes com um único ponto de entrada e escala automática.

Segui a Opção B do enunciado — conta pessoal AWS. Criei o cluster com `eksctl create cluster`, que já cuida de gerar as IAM roles corretas sozinho, sem eu precisar depender de uma role fixa como a `LabRole` do AWS Academy. Isso me deixou livre pra usar IRSA sem restrição, tanto no Ingress Controller quanto, de forma bem mais granular, nos service accounts do `evaluation-service` e do `analytics-service` (Seção 5.3).

1.1 Ambiente de desenvolvimento

Pra não misturar o trabalho com a minha estação pessoal, fiz todo o desenvolvimento numa VM dedicada (Ubuntu 24.04 sobre KVM/libvirt, 4 vCPU, 6 GB de RAM), provisionada inteira por cloud-init. Deixei Docker, kubectl, Helm, eksctl, AWS CLI e as ferramentas de carga já dentro dela — o ambiente inteiro é reconstruído do zero a partir de um único arquivo, sem eu precisar repetir nenhum passo manual se algo der errado.

2. Arquitetura da Solução

Organizei a solução em duas camadas. O cluster Kubernetes orquestra os cinco microsserviços e expõe um ponto único de entrada pelo Ingress. Os serviços gerenciados da AWS cuidam da persistência, do cache e da mensageria. Não deixei nenhum estado vivendo dentro do cluster — é isso que mantém os pods descartáveis e permite escalá-los sem cuidado especial.

Microserviço	Responsabilidade	Persistência / Integração
auth-service (Go)	Autenticação e gestão de chaves de API	Amazon RDS (PostgreSQL) dedicado
flag-service (Python)	CRUD das definições de feature flags	Amazon RDS (PostgreSQL) dedicado
targeting-service (Python)	Regras de segmentação de público (JSONB)	Amazon RDS (PostgreSQL) dedicado
evaluation-service (Go)	Hot path — retorna a decisão true / false	Amazon ElastiCache (Redis), publica eventos no SQS
analytics-service (Python)	Consome eventos da fila e grava dados de análise	Amazon SQS (consumidor), Amazon DynamoDB

Tabela 1 — Responsabilidades e dependências de dados de cada microserviço.

2.1 Fluxo de uma requisição

O tráfego externo entra por um Load Balancer que o Nginx Ingress Controller provisiona sozinho, e é roteado por prefixo até o Service `ClusterIP` correspondente. O caminho que mais me preocupou foi o do `evaluation-service`: primeiro ele consulta o Redis, e se der cache miss, busca ao mesmo tempo a definição da flag no `flag-service` e a regra de segmentação no `targeting-service`, junta os dois resultados, grava no cache com TTL de 30 segundos e responde. Só depois disso a decisão é publicada, de forma assíncrona, na fila SQS — não deixo essa publicação segurar a resposta ao cliente.

A avaliação em si é determinística: calculo um bucket de 0 a 99 a partir do hash SHA-1 de `user_id + flag_name`. O mesmo usuário sempre recebe a mesma resposta pra mesma flag, sem eu guardar estado por usuário em lugar nenhum — o que é essencial pra qualquer réplica poder atender qualquer requisição, indiferente de qual pod respondeu da última vez.

Isolei cada serviço no seu próprio namespace, o que evita colisão de nomes de recursos e deixa RBAC e cotas configuráveis por área, de forma independente.




Figura 1 — Arquitetura do ToggleMaster na nuvem: os 5 microserviços, os 6 recursos de dados da AWS e o caminho do tráfego externo.

3. Containerização com Docker

Escrevi um Dockerfile próprio pra cada microserviço, com build multi-stage, separando o estágio de compilação do estágio de execução — assim nenhuma ferramenta de build sobra na imagem final.

3.1 Estratégia por linguagem

Nos serviços em Go, compilo em `golang:1.21-alpine` e rodo a partir de `gcr.io/distroless/static-debian12:nonroot`. Gero o binário estático (`CGO_ENABLED=0`), com `-trimpath` tirando os caminhos da minha máquina de build e `-ldflags="-s -w"` descartando símbolos e informação de depuração. A imagem final não tem shell nem gerenciador de pacotes — não sobra nenhum binário além da própria aplicação, o que reduz bastante a superfície de ataque.

Nos serviços em Python, uso `python:3.11-slim` nos dois estágios: o primeiro monta um virtualenv, e só ele atravessa pro estágio final — deixo o `pip` e os artefatos de compilação pra trás. A execução roda com um usuário não-root (uid 10001), sob Gunicorn.

```
# evaluation-service — Dockerfile multi-stage

FROM golang:1.21-alpine AS build
WORKDIR /src
COPY go.mod go.sum ./
RUN go mod download          # camada separada: só invalida se as dependências mudarem
COPY . .
RUN CGO_ENABLED=0 GOOS=linux go build \
    -trimpath -ldflags="-s -w" \
    -o /out/evaluation-service .

FROM gcr.io/distroless/static-debian12:nonroot
COPY --from=build /out/evaluation-service /evaluation-service
EXPOSE 8004
USER nonroot:nonroot
ENTRYPOINT ["/evaluation-service"]
```

3.2 Imagens produzidas

Imagem	Tamanho final	Base do estágio de execução
auth-service	16,5 MB	distroless/static
evaluation-service	21,8 MB	distroless/static
flag-service	248 MB	python:3.11-slim
targeting-service	248 MB	python:3.11-slim
analytics-service	287 MB	python:3.11-slim

Tabela 2 — Tamanho das imagens após o build multi-stage.

Não me surpreendeu a diferença de mais de dez vezes entre Go e Python: o binário Go é autocontido e não precisa de runtime, enquanto as imagens Python carregam o interpretador e a biblioteca padrão junto.

3.3 Ambiente local — Docker Compose

Escrevi um `docker-compose.yml` que sobe os nove contêineres que o enunciado pede: os cinco microsserviços e os quatro bancos.

Contêiner	Porta	Função
auth-service	8001	Chaves de API
flag-service	8002	CRUD das feature flags
targeting-service	8003	Regras de segmentação
evaluation-service	8004	Hot path da decisão
analytics-service	8005	Worker SQS → DynamoDB
postgres-auth	—	Banco auth_db
postgres-flags	—	Bancos flag_db e targeting_db
redis	—	Cache do evaluation-service
dynamodb-local	—	Tabela de eventos de analytics

Tabela 3 — Os nove contêineres do ambiente local.

Como o enunciado pede duas instâncias PostgreSQL locais pra três serviços, fiz o `postgres-flags` hospedar dois bancos logicos, criados já na inicialização do volume. Montei os schemas direto dos próprios repositórios (`services/*/db/init.sql`) em vez de copiar pra dentro do `compose`, pra não correr o risco de ter duas versões do mesmo schema saindo de sincronia sem eu perceber. Na AWS a separação passa ser física, como conto na Seção 4.

Três decisões de configuração que tomei aqui merecem registro:


- Configurei os serviços de aplicação pra só subirem depois que os bancos reportam `healthy` (`depends_on` com `condition: service_healthy`), o que evita falha de corrida no boot.
- Fiz o `analytics-service` rodar com um único worker, de propósito. O consumidor SQS inicia no `import` do módulo, então cada worker do Gunicorn abriria um consumidor independente da mesma fila dentro do mesmo pod — com `--workers 1` eu garanto a relação 1 pod = 1 consumidor, e a contagem de réplicas passa a ser proporcional à vazão real de mensagens. É essa premissa que sustenta a escala automática que descrevo na Seção 7.
- A tabela do DynamoDB Local eu crio com um contêiner efêmero, sob um profile dedicado, que executa e encerra — não entra na contagem dos nove contêineres.

3.4 Validação do ambiente local

Depois de rodar `docker compose up -d --build`, os nove contêineres sobem e os bancos reportam `healthy`. Testei o fluxo de ponta a ponta:

Verificação	Resultado obtido
Health dos serviços	<code>{"status": "ok"}</code> nas portas 8001, 8002, 8003 e 8004
Criação de chave de API	POST <code>/admin/keys</code> autenticado com a <code>MASTER_KEY</code> retornou uma chave <code>tm_key_...</code> de 71 caracteres
Criação da feature flag	<code>enable-new-dashboard</code> criada com <code>is_enabled: true</code>
Criação da regra	<code>{"type": "PERCENTAGE", "value": 50}</code> gravada como JSONB
Avaliação de 8 usuários	4 resultados <code>true</code> e 4 <code>false</code> — bate com a regra de 50%, e o resultado é determinístico por <code>user_id + flag_name</code>
Cache	Chave <code>flag_info:enable-new-dashboard</code> presente no Redis; o log confirma <code>Cache MISS</code> seguido de <code>Cache HIT</code>
DynamoDB Local	Tabela criada com chave de partição <code>event_id</code> (String)

Tabela 4 — Validação funcional do ambiente local.



```
udefault@forge: ~/fiap-tc-fase2 - docker compose ps
SERVICE                                STATUS
analytics-service                       Up 57 minutes (healthy)
auth-service                             Up 3 days
dynamodb-local                           Up 3 days
evaluation-service                       Up 3 days
flag-service                             Up 3 days (healthy)
postgres-auth                            Up 3 days (healthy)
postgres-flags                           Up 3 days (healthy)
redis                                    Up 3 days (healthy)
targeting-service                        Up 3 days (healthy)
```

Figura 2 — Ambiente local completo em execução, captura real de `docker compose ps` que tirei na minha própria VM.

4. Infraestrutura Provisionada na AWS

Provisionei toda a infraestrutura via AWS CLI (Opção B), na região `us-east-1`. Os nós do cluster usam a IAM Role `eksctl-togglemaster-nodegroup-togg-NodeInstanceRole`, e criei mais duas roles dedicadas via IRSA (Seção 5.3) pros pods que precisam falar com SQS e DynamoDB.

Recurso	Qtd.	Nome / Identificador	Configuração
Cluster Kubernetes	1	<code>togglmaster</code>	EKS 1.31 · us-east-1 · criado via <code>eksctl create cluster --with-oidc</code>
Managed Node Group	1	<code>togglmaster-nodes</code>	<code>t3.medium</code> · Min=1 / Desejado=2 / Máx=4
Repositórios ECR	5	um por microserviço, tag <code>v1</code>	Imagens da Seção 3 publicadas e confirmadas com <code>aws ecr list-images</code>
RDS PostgreSQL	3	<code>togglmaster-auth</code> · <code>togglmaster-flag</code> · <code>togglmaster-targeting</code>	<code>db.t3.micro</code> · PostgreSQL 16.4 · Single-AZ · <code>--no-publicly-accessible</code>
ElastiCache Redis	1	<code>togglmaster-evaluation-cache</code>	<code>cache.t3.micro</code> · Redis 7.1
Tabela DynamoDB	1	<code>ToggleMasterAnalytics</code>	Chave de partição <code>event_id</code> (String) · billing <code>PAY_PER_REQUEST</code>
Fila SQS Standard	1	<code>togglmaster-evaluation-events</code>	Produtor: <code>evaluation-service</code> · Consumidor: <code>analytics-service</code>

Tabela 5 — Inventário dos recursos de nuvem que provisionei na Etapa 2 (todos `available / ACTIVE`, confirmados via AWS CLI).

O `eksctl`, sem `--vpc-*` explícito, provisiona uma VPC nova pro cluster — neste caso `192.168.0.0/16` — diferente da VPC padrão da minha conta (`172.31.0.0/16`), que é onde eu já tinha criado o RDS e o ElastiCache. Só percebi isso na prática quando os pods começaram a dar `i/o timeout` tentando falar com o Redis: eram duas redes isoladas, sem rota entre si, e eu não tinha reparado que o `eksctl` faz isso por padrão. Como os blocos CIDR não colidem, resolvi com VPC Peering entre as duas, adicionando rota nas route tables dos dois lados — a rota inversa na VPC padrão, e a rota direta na route table que as duas subnets públicas dos nós do EKS compartilham, já que por padrão o `eksctl` não usa `--node-private-networking`. Numa próxima rodada, prefiro apontar o `eksctl` direto pras subnets da VPC padrão via `--vpc-private-subnets / --vpc-public-subnets`, o que evitaria esse peering todo — foi um retrabalho que eu poderia ter previsto se tivesse lido a documentação do `eksctl` com mais calma antes de rodar o comando.

Com `--no-publicly-accessible` (que é o correto, e o que o enunciado pede), os endpoints do RDS só resolvem DNS de dentro da VPC — eu sabia disso, mas só senti a consequência na prática quando fui rodar as migrações de schema (`db/init.sql` de cada serviço): não dava pra conectar direto da minha máquina de desenvolvimento, então subi um pod temporário com `postgres:16-alpine` dentro do próprio cluster (`kubectl run + kubectl cp + kubectl exec -- psql`) só pra rodar os três arquivos SQL.

Depois de criar cada recurso, anotei os endpoints, nomes de tabela e ARNs, e injetei tudo no cluster como Secrets e ConfigMaps (Seção 5) — não deixei nenhuma credencial no código-fonte nem nas imagens que publiquei no ECR. Uma coisa que precisei ter cuidado: o nome da tabela e a chave de partição do DynamoDB não são escolha minha livre. O `analytics-service`

já grava o item usando `event_id` como partition key e lê o nome da tabela da variável `AWS_DYNAMODB_TABLE`, então tive que provisionar a tabela respeitando exatamente esse contrato — senão o worker só falharia em runtime, ao tentar gravar o primeiro evento.

5. Orquestração com Kubernetes

Isolei cada microsserviço no seu próprio namespace, com os manifestos de Deployment, Service (`ClusterIP`), Secret e ConfigMap aplicados via `kubectl apply`. As imagens referenciadas nos Deployments apontam pros repositórios do ECR que publiquei na Seção 4, tag `v1`. No estado final que consegui, os 9 pods ficaram `Running` e `Ready` nos 5 namespaces.

5.1 Estrutura das Secrets

Não coloco os valores reais neste relatório nem no repositório versionado — só a estrutura do manifesto:

```
apiVersion: v1
kind: Secret
metadata:
  name: auth-db-credentials
  namespace: auth
type: Opaque
data:
  DATABASE_URL: [base64 – definido em tempo de deploy]
  MASTER_KEY: [base64 – definido em tempo de deploy]
```

Todas as Secrets seguem a codificação em base64 que o Kubernetes exige. Gero elas a partir de um arquivo `.env` local que não versiono (fica fora via `.gitignore`) e só viram YAML no momento do deploy.

5.2 Boas práticas que apliquei em todos os Deployments

- Requests e Limits de CPU e memória em todos os contêineres, pra um pod não consumir recursos além do necessário e atrapalhar o agendamento dos outros no mesmo nó.
- Readiness e Liveness Probes via `GET /health`, presente nos cinco serviços. Ajustei o `initialDelaySeconds` pro tempo de boot de cada linguagem: os binários Go respondem quase na hora, enquanto os serviços Python sob Gunicorn precisam de uma folga maior.
- Separação por Namespace, o que me permite aplicar `ResourceQuota` de forma independente por serviço.
- Um worker por pod no `analytics-service`, pelo motivo que já expliquei na Seção 3.3 — é o que torna a contagem de réplicas uma medida fiel da capacidade de consumo da fila.

5.3 Acesso a SQS e DynamoDB — IRSA com política de menor privilégio

O `evaluation-service` e o `analytics-service` precisam de credenciais AWS pra falar com SQS e DynamoDB. A role padrão dos nós do EKS (`AmazonEKSWorkerNodePolicy` + `AmazonEC2ContainerRegistryPullOnly`) não traz essas permissões, e deixei assim de propósito: se eu desse essa permissão ao node inteiro, qualquer pod agendado ali herdaria o acesso, o que violaria o princípio do menor privilégio.

Optei por IRSA (IAM Roles for Service Accounts), possível porque criei o cluster com `--with-oidc`. Criei duas service accounts dedicadas (`evaluation-sa`, `analytics-sa`) via `eksctl create iamserviceaccount`, cada uma com sua própria IAM Role, anexadas a uma policy com três declarações separadas em vez de uma permissão genérica de SQS/DynamoDB:

```
{
  "Statement": [
    { "Sid": "SqsEvaluationProducer",
      "Action": ["sqs:SendMessage"], "Resource": "arn:aws:sqs:...:togglemaster-evaluation-events" },
    { "Sid": "SqsAnalyticsConsumer",
      "Action": ["sqs:ReceiveMessage", "sqs:DeleteMessage", "sqs:GetQueueAttributes"],
      "Resource": "arn:aws:sqs:...:togglemaster-evaluation-events" },
    { "Sid": "DynamoDbAnalytics",
      "Action": ["dynamodb:PutItem"], "Resource": "arn:aws:dynamodb:...:table/ToggleMasterAnalytics" }
  ]
}
```

Dei ao `evaluation-service` só a permissão de enviar mensagens, porque é o produtor. Ao `analytics-service` dei só receber e apagar, porque é o consumidor, e só `PutItem` na tabela específica — nunca `Scan`, `Query` ou qualquer leitura em massa. Referenciei a service account de cada Deployment em `spec.template.spec.serviceAccountName`.

6. Ingress e Acesso Externo

Instalei o Nginx Ingress Controller via Helm (`ingress-nginx/ingress-nginx`), com o Service do controller do tipo `LoadBalancer` anotado pra provisionar um Network Load Balancer (`service.beta.kubernetes.io/aws-load-balancer-type: nlb`). Quem provisiona o NLB é o cloud-controller-manager nativo do EKS, então não precisei instalar o AWS Load Balancer Controller à parte. Escrevi o manifesto Ingress pra rotear por prefixo de rota:

Rota	Service de destino	Porta
<code>/auth</code>	<code>auth-service</code>	8001
<code>/flags</code>	<code>flag-service</code>	8002
<code>/targeting</code>	<code>targeting-service</code>	8003
<code>/evaluate</code>	<code>evaluation-service</code>	8004
<code>/events</code>	<code>analytics-service</code>	8005

Tabela 6 — Regras de roteamento do manifesto Ingress.

O `hostname` do NLB que provisionei é `abc9bb709ba2943ea8099ae621c5939a-76d2e22c4f7f64c3.elb.us-east-1.amazonaws.com`. Validei o acesso externo chamando as quatro rotas por curl:

```
$ curl http://abc9bb709ba2943ea8099ae621c5939a-76d2e22c4f7f64c3.elb.us-east-1.amazonaws.com/auth/health
{"status":"ok"}
$ curl http://abc9bb709ba2943ea8099ae621c5939a-76d2e22c4f7f64c3.elb.us-east-1.amazonaws.com/flags/health
{"status":"ok"}
$ curl http://abc9bb709ba2943ea8099ae621c5939a-76d2e22c4f7f64c3.elb.us-east-1.amazonaws.com/targeting/health
{"status":"ok"}
$ curl http://abc9bb709ba2943ea8099ae621c5939a-76d2e22c4f7f64c3.elb.us-east-1.amazonaws.com/evaluate/health
{"status":"ok"}
```

As quatro rotas me responderam HTTP 200 passando pelo balanceador de verdade, não só por port-forward, o que confirma que o rewrite-target que descrevo abaixo está funcionando: o Ingress recebe `/auth/health` e o `auth-service` recebe só `/health`, que é o que o código-fonte espera.

As rotas dos serviços são `/health`, `/flags/<nome>`, `/rules/<flag>` e `/evaluate`, sem o prefixo do Ingress. Sem reescrever o caminho (`rewrite-target`), o backend responde 404 pra todo o tráfego que passa pelo balanceador — mesmo funcionando perfeitamente quando eu testava por port-forward, o que quase me fez achar que estava tudo certo até eu testar pela URL pública de verdade.

7. Escalabilidade Automática (HPA)

Instalei o Metrics Server como addon gerenciado do EKS (conto o motivo na Seção 8.3) e confirmei com `kubectl top nodes` antes de rodar qualquer teste de carga.

Serviço	Métrica	Alvo	Mín.	Máx.
evaluation-service	Utilização média de CPU	70%	2	6
analytics-service	Utilização média de CPU	65%	1	5

Tabela 7 — Configuração dos HorizontalPodAutoscalers que criei, ambos aplicados e ativos no cluster.

7.1 Teste de carga — evaluation-service

Gerei a carga com `ab` (ApacheBench) direto na rota `/evaluate` do NLB, simulando tráfego real de cliente externo, não port-forward:

```
$ ab -n 200000 -c 60 -t 240 "http://<NLB>/evaluate/evaluate?user_id=load-user&flag_name=enable-new-dashboard"
```

Momento	CPU (uso/alvo)	Réplicas
Antes da carga (baseline)	1% / 70%	2
Sob carga (pico observado)	273% / 70%	4
Após o fim da carga (cooldown de 180s)	1% / 70%	2 (scale-down automático)

Tabela 8 — Comportamento do HPA do evaluation-service sob carga real, que medi com `kubectl top pods` e `kubectl get hpa`.

O HPA reagiu dentro da janela de `stabilizationWindowSeconds: 0` que configurei pro scale-up, dobrando as réplicas de 2 pra 4 pouco depois do início da carga, e voltou ao piso de 2 depois do período de estabilização de scale-down, sem oscilar entre os dois estados.

7.2 Teste do fluxo assíncrono — analytics-service

Em vez de mandar mensagens manuais pelo Console, testei pelo caminho real do sistema: requisições de avaliação passando pelo Ingress, cada uma disparando um evento assíncrono pro SQS.

Passo	Resultado
20 requisições a <code>/evaluate/evaluate</code> via NLB	200 OK em todas, cada uma publicando 1 evento no SQS de forma assíncrona (<code>go a.sendEvaluationEvent</code>)
Consumo pelo <code>analytics-service</code>	Long-polling de até 20s, sem eu precisar intervir
Itens gravados no DynamoDB	20 de 20, confirmei com <code>aws dynamodb scan --select COUNT</code>

Tabela 9 — Validação do fluxo `evaluation-service` → SQS → `analytics-service` → DynamoDB, de ponta a ponta na infraestrutura real.

Acho importante explicar por que a métrica de escala do `analytics-service` importa: o HPA por CPU mede o efeito (o processamento gasto ao tratar as mensagens), não a causa (a profundidade da fila). Funciona, mas reage só depois que a carga já virou consumo de CPU, e nunca escala a zero. Se eu tivesse usado KEDA, observando `ApproximateNumberOfMessagesVisible` direto, escalaria de 0 a N, o que é mais correto pra uma carga orientada a eventos. Essa distinção só se sustenta, aliás, por causa da decisão de `--workers 1` que tomei na Seção 3.3 — com vários consumidores por pod, nem a profundidade da fila nem a CPU seriam proporcionais ao número de réplicas.

8. Desafios e Decisões Técnicas

8.1 O código-fonte que recebi não compilava

O primeiro passo do enunciado é rodar o ecossistema localmente. Ao clonar os cinco repositórios de `github.com/FIAP-TCs`, descobri que os dois serviços escritos em Go simplesmente não compilavam. Não é questão de estilo — são erros que o compilador rejeita, o que impede qualquer `go build` e, por tabela, o build das imagens. Usei os três serviços em Python sem alteração no código.

#	Arquivo	Defeito e correção
1	auth-service/go.mod	require github.com/jackc/pgx/v4/stdlib v4.18.3 — stdlib é um pacote dentro do módulo pgx/v4, não um módulo próprio. O Go recusa com version "v4.18.3" invalid: should be v0 or v1, e trava todo comando go. Corrigi removendo a linha.
2	auth-service/main.go	Driver pgx/v4/stdlib importado sem _, mas nunca referenciado — só é usado pelo efeito colateral do init(). Corrigi trocando pro import em branco.
3	auth-service/main.go	"fmt" importado e não usado. Removi.
4	auth-service/handlers.go	"crypto/sha256" e "encoding/hex" importados e não usados — quem os usa é key.go. Removi os dois.
5	auth-service/key.go	"fmt" importado e não usado. Removi.
6	evaluation-service/go.sum	O arquivo era uma cópia do go.mod (começava com module evaluation-service). O Go recusa com malformed go.sum: wrong number of fields 2. Descartei e regerei com go mod tidy.
7	evaluation-service/evaluator.go	Usava os.Getenv("SERVICE_API_KEY") sem importar "os" (undefined: os). Adicionei o import.
8	evaluation-service/evaluator.go	"context" importado e não usado — o ctx das chamadas ao Redis é a variável global de main.go. Removi.

Tabela 10 — Defeitos de compilação que corrigi no código-fonte recebido.

Depois das correções, `go build ./...` conclui sem erro nos dois serviços. Deixei o diagnóstico completo de cada defeito no arquivo `PATCHES.md`, na raiz do repositório.

8.2 Dependências declaradas sem travas suficientes

Encontrei dois problemas de dependência que impediriam a subida dos contêineres, e resolvi os dois sem tocar no código-fonte nem no `requirements.txt` original:

- Flask 2.2.2 sem pin de Werkzeug. O `requirements.txt` fixa `Flask==2.2.2`, mas não fixa o Werkzeug. Como o Flask 2.2.2 só declara `Werkzeug>=2.2.2`, o pip resolve pra série 3.x, que removeu `werkzeug.urls.url_quote` — import que o Flask 2.2 ainda faz. O contêiner morreria com `ImportError` antes do primeiro request. Resolvi com um `constraints.txt` travando `Werkzeug<3`, que complementa o arquivo original em vez de substituí-lo.
- boto3 velho demais pro DynamoDB Local. O `app.py` do `analytics-service` cria os clientes com `session.client("dynamodb")`, sem `endpoint_url` e sem nenhuma forma de configurá-lo por fora. As variáveis `AWS_ENDPOINT_URL_DYNAMODB` e `AWS_ENDPOINT_URL_SQS` resolveriam, mas só passaram a ser lidas pelo botocore a partir da série 1.31, e o `requirements.txt` fixa a 1.26.50. Resolvi com um `requirements-container.txt`, instalado depois do original, elevando o boto3 — a mesma imagem serve os dois ambientes: localmente eu aponto a variável pro DynamoDB Local, na AWS simplesmente não defino ela.

8.3 Dependência circular no bootstrap

O `evaluation-service` precisa de uma chave de API pra conversar com o `flag-service` e o `targeting-service`, mas essa chave só existe depois que o `auth-service` já estiver no ar — não tem como eu injetar ela antes da primeira subida. Documentei um bootstrap em duas etapas: subo a stack, gero a chave, gravo ela e recrio só o `evaluation-service`.

Caí numa armadilha durante a validação: carregar o `.env` no shell (`set -a; . ./env`) antes de chamar o `docker compose` faz o serviço receber a chave vazia e levar 401 do `flag-service` — mesmo com o valor certo gravado no arquivo. A causa é a ordem de precedência do Docker Compose: variável já exportada no ambiente vence o arquivo `.env`. O sintoma engana, porque testei a mesma chave isolada com `curl` e ela respondeu 200 sem problema — o que me fez perder um tempo bom desconfiando de tudo, menos do próprio shell. Só cheguei no diagnóstico comparando o valor do arquivo com o que o contêiner de fato recebia, via `docker inspect`.

8.4 HPA por CPU × KEDA por profundidade de fila

Numa conta pessoal como a que usei, a escolha mais correta pro `analytics-service` seria o KEDA, escalando direto pela métrica `ApproximateNumberOfMessagesVisible` da fila SQS, evitando o atraso natural do HPA por CPU — que só reage depois que a carga já virou consumo de processamento. No ambiente AWS Academy o KEDA não seria viável, porque depende de IRSA pra criar roles próprias, e nesse caso eu adotaria o workaround que o próprio enunciado sugere: escalar por CPU. Discuto isso com mais detalhe na Seção 7.

8.5 Diferença de propósito entre os três data stores

- Uso o Amazon RDS (PostgreSQL) pros dados relacionais e transacionais dos serviços de domínio (auth, flag, targeting), onde consistência forte e relacionamento entre entidades são essenciais. É o caso do `targeting-service`, que guarda a regra como JSONB mas depende da unicidade de `flag_name` garantida pelo banco.
- Uso o Amazon ElastiCache (Redis) como cache em memória de baixíssima latência pro hot path, com TTL de 30 segundos. Prioriza velocidade de leitura em troca de persistência — perder o cache custa só um miss, nunca um dado de verdade.
- Uso o Amazon DynamoDB pros eventos de analytics em alto volume, com escrita desnormalizada, priorizando throughput e escala horizontal sobre consultas relacionais complexas. Cada evento é independente e nunca é atualizado, o que dispensa transação.

8.6 Isolamento do ambiente de desenvolvimento

Fiz todo o trabalho numa VM dedicada, provisionada por cloud-init (Seção 1.1), em vez de instalar o ferramental direto na minha estação de trabalho. O ganho não é só organização: o ambiente é descartável e recriável, o que elimina a classe de problema em que algo funciona só por causa de um resíduo de configuração local que eu mesmo esqueceria de reproduzir depois.

8.7 Achados reais do provisionamento (Opção B)

Achado	Como contornei
Versão de EKS do enunciado (1.29) fora de suporte	Bati com o erro <code>invalid version, 1.29 is no longer supported</code> . Usei a versão suportada mais próxima, 1.31 — o enunciado é de out/2025 e a AWS já descontinuou a série.
Conta no AWS Free Plan trava RDS em 2 instâncias	Descobri que não é a cota padrão de serviço (essa é 40), é uma restrição do <code>accountPlanType: FREE</code> . Erro: <code>InstanceQuotaExceeded... upgrade your account plan</code> . Resolvi com upgrade pra <code>PAID</code> , sem custo imediato — os créditos gratuitos da minha conta continuaram intactos.
<code>eksctl</code> cria uma VPC isolada da VPC padrão	Meus pods ficaram sem rota pro RDS/ElastiCache, criados na VPC padrão. Resolvi com VPC Peering e rotas nos dois lados (detalhe na Seção 4).
Manifest comunitário do Metrics Server colide com o addon gerenciado do EKS	O EKS já instala o Metrics Server como addon nativo. Quando apliquei a manifest padrão do GitHub por cima, ela trocou os labels do pod e quebrou o Service correspondente (<code>MissingEndpoints</code>). Corrigi removendo e recriando o addon gerenciado (<code>aws eks delete-addon / create-addon</code>) — aprendi que nunca devo sobrepor um addon gerenciado com a manifest da comunidade.
RDS privado inacessível da minha máquina de desenvolvimento	Por desenho (<code>--no-publicly-accessible</code>). Rodei as migrações de schema de dentro do cluster, via um pod temporário com <code>psql</code> (Seção 4).
Node role sem permissão pra SQS/DynamoDB	A role padrão dos nós do EKS não traz essas permissões, de propósito — pra não dar acesso a todo pod agendado no nó. Resolvi com IRSA e política de menor privilégio (Seção 5.3), em vez de anexar a permissão na role do nó inteiro.

Tabela 11 — Achados reais durante o provisionamento na AWS, com a correção que apliquei em cada um.

9. Considerações Finais e Links do Projeto

A migração para microsserviços concretizou o que o meu próprio relatório da Fase 1 já apontava como candidato a extração — em especial separar o caminho de leitura de alta frequência, agora com cache próprio e escala independente, do CRUD administrativo das flags. Cada serviço passou a ter seu próprio ciclo de implantação, sua própria persistência e sua própria política de escala, o que resolve a escalabilidade grosseira que eu já tinha apontado como a principal desvantagem do monolito.

O ganho mais fácil de enxergar está na containerização: imagens de 16,5 MB e 21,8 MB pros serviços em Go, sem shell nem gerenciador de pacotes, me deram uma superfície de ataque e um tempo de pull muito menores do que uma imagem base convencional entregaria.

Mas o aprendizado que mais pesou pra mim não veio da orquestração — veio da base que recebi. Precisei resolver oito defeitos de compilação e dois problemas de dependência antes que qualquer contêiner subisse. Aprendi, na prática, que não adianta discutir estratégia de autoescala se o `go build` nem passa.

Item	Link
Repositório (infraestrutura, compose, manifestos e relatório)	github.com/karlos-rodrigues/togglemaster-fase2
Forks dos 5 microsserviços com as correções da Seção 8.1	github.com/karlos-rodrigues/{auth,flag,targeting,evaluation,analytics}-service
Vídeo de demonstração (até 20 min)	https://youtu.be/MWbgBMLYnl8
Diagrama de arquitetura	Figura 1, Seção 2
Badge Google Cloud Skills Boost (pontuação extra)	skills.google/public_profiles/e2a52c57-829c-4a3d-aa01-f17305b8d64f
Repositório da Fase 1 (referência)	https://github.com/dougls/toggle-master-monolith

Tabela 12 — Links da entrega.

Apêndice A — Evidências de Execução

Capturas comprovando cada etapa, que vou referenciar pelos tempos correspondentes no vídeo.

Item	Evidência	Status
A.1	go build concluindo nos dois serviços Go após as correções	Disponível
A.2	docker images — tamanho das cinco imagens	Disponível
A.3	docker compose ps — os nove contêineres (Figura 2)	Disponível
A.4	Fluxo ponta a ponta: chave de API, flag, regra e avaliações	Disponível
A.5	Recursos provisionados na AWS — aws rds/elasticache/dynamodb/sqs describe-*	Disponível
A.6	Cluster ativo e kubectl get pods -A — 9/9 Running nos 5 namespaces	Disponível
A.7	Ingress: curl nas 4 rotas via hostname do NLB, todas 200	Disponível
A.8	Teste de carga (ab) e kubectl get hpa escalando de 2 para 4 réplicas	Disponível
A.9	20 avaliações via Ingress → SQS → analytics-service → 20 itens no DynamoDB	Disponível

Apêndice B — De-para: Requisitos do Enunciado × Entregas

Legenda: ✓ atendido · ~ parcial · ⚪ pendente

Requisito	Status	Onde
1 — Dockerfile otimizado (multi-stage) para os 5 microsserviços	✓	Seção 3.1, Tabela 2
1 — <code>docker-compose.yml</code> único com 5 apps + 4 bancos	✓	Seção 3.3, Tabela 3
1 — Ecossistema executando e compreendido localmente	✓	Seção 3.4, Tabela 4
2 — Cluster Kubernetes provisionado	✓	Seção 4
2 — 5 repositórios ECR com as imagens publicadas	✓	Seção 4
2 — 3 instâncias RDS PostgreSQL independentes	✓	Seção 4
2 — 1 cluster ElastiCache Redis	✓	Seção 4
2 — 1 tabela DynamoDB e 1 fila SQS Standard	✓	Seção 4
3 — Metrics Server instalado	✓	Seção 7
3 — Nginx Ingress Controller instalado	✓	Seção 6
4 — Manifestos: Namespace, Deployment, Service, Secret, ConfigMap	✓	Seção 5
4 — Ingress com roteamento por prefixo de rota	✓	Seção 6
4 — Requests/Limits, Secrets em base64, Probes e Namespaces	✓	Seção 5.2
5 — HPA no evaluation-service e no analytics-service	✓	Seção 7
Vídeo — compose com 9 contêineres, cluster, pods, Ingress e escala	✓	0:00–1:42 slides, 1:42–10:02 gravação real
Vídeo — explicar a escolha da métrica de escala do analytics-service	✓	Seções 7 e 8.4
Vídeo — explicar a diferença de propósito entre os 3 data stores	✓	Seção 8.5
Vídeo — explicar a arquitetura e os desafios encontrados	✓	Seções 2 e 8
Relatório — nome, RM e Discord dos participantes	✓	Capa
Relatório — links dos repositórios e do vídeo	✓	Seção 9, Tabela 12
Extra — trilha Google Cloud Skills Boost (10 pontos, opcional)	✓	Seção 9, Tabela 12